

PORÓWNANIE EFEKTYWNOŚCI SIECI NEURONOWYCH I MODELI EKONOMETRYCZNYCH WE WSPOMAGANIU DECYZJI KREDYTOWYCH

Anna Bechler

Katedra Badań Operacyjnych, Uniwersytet Łódzki, Łódź

1 WPROWADZENIE

W świetle obowiązującego w Polsce prawa *kredyt* stanowi umowę, na mocy której bank zobowiązuje się oddać do dyspozycji kredytobiorcy kwotę środków pieniężnych z przeznaczeniem na ustalony cel, a kredytobiorca jest zobowiązany do zwrotu wykorzystanego kredytu wraz z odsetkami w oznaczonych terminach spłaty. Jak pokazuje bankowa praktyka, działalność kredytowa stanowi jeden z najistotniejszych elementów, decydujących o kondycji finansowej banku. Z tego właśnie powodu zarządzanie ryzykiem kredytowym, a w szczególności jego ilościowa ocena, odgrywa zasadniczą rolę w złożonym procesie zarządzania bankiem, a także przyjętej strategii rozwojowej. Podstawową metodą oceny ryzyka, związanego z pojedynczą umową kredytową, jest analiza wniosku złożonego przez potencjalnego dłużnika. Przyznanie bądź odmowa udzielenia kredytu leży w głównej mierze w gestii pracownika bankowego, badającego zdolność kredytową danego kandydata. Celem zobjektywizowania przeprowadzanej oceny coraz częściej stosuje się ilościowe metody wspomaganie procesu decyzyjnego, służące właściwemu doborowi kredytobiorców. Wśród metod tych znajdują się: *analiza dyskryminacyjna, analiza regresji (modele liniowe, probitowe i logitowe), drzewa decyzyjne, metody „najbliższego sąsiedztwa”, programowanie matematyczne, sieci neuronowe, systemy eksperckie, czy też algorytmy genetyczne*. Pomagają one zaklasyfikować klientów do odpowiedniej grupy ryzyka kredytowego, na podstawie obiektywnych i mierzalnych cech, co przyczynia się do minimalizacji prawdopodobieństwa

przyznania kredytu osobom nierzetelnym, a tym samym poprawy jakości portfeli kredytowych. Wysoce wyspecjalizowane procedury, wykorzystujące metody statystyczne, pozwalają jednocześnie zredukować koszty związane z analizą wniosków kredytowych. Należy jednak pamiętać, iż ich zastosowanie powinno odnosić się do jednorodnej grupy podmiotów. Poprawna konstrukcja i późniejsze modyfikacje wspomnianych modeli wymagają ponadto odpowiedniej bazy danych, zawierającej informacje zarówno na temat przyznanych kredytów, jak i decyzji odmownych.

2 ZBIÓR DANYCH EMPIRYCZNYCH

Dane pierwotne wykorzystane w prezentowanych badaniach pochodzą z jednego z łódzkich banków i dotyczą osób fizycznych posiadających obywatelstwo polskie, które ubiegały się o przyznanie ratalnych kredytów konsumpcyjnych na zakup samochodu. Analizowana próba obejmuje lata 1998-1999 i liczy ogółem 200 obserwacji (176 decyzji pozytywnych i 24 negatywne). Każda obserwacja zawiera zbiór cech ilościowych i jakościowych, charakteryzujących potencjalnego kredytobiorcę, które mogą być pomocne w ocenie jego wiarygodności oraz zdolności kredytowej, a tym samym ustaleniu ryzyka związanego z daną umową. Ponadto zebrane informacje dotyczą: *wysokości kredytu, odsetek, długości okresu kredytowania, proponowanych zabezpieczeń oraz ostatecznej decyzji inspektorów kredytowych*.

Zgromadzony materiał statystyczny, po odpowiednim zakodowaniu, został poddany wstępnej

analizie, w wyniku której część cech diagnostycznych wyłączono z toku dalszych rozważań z uwagi na rzadkość występowania w omawianej próbie, bądź też silne skorelowanie z innymi charakterystykami. Ostatecznie wyselekcjonowano zbiór 35 cech, wykorzystanych zarówno przy budowie modelu ekonometrycznego, jak i sieci neuronowej.

Tabela 1. Finalny zbiór cech diagnostycznych.

Nazwa zmiennej	Cecha diagnostyczna	Miano (Rodzaj) ⁸
NIESAM	Stan cywilny	Z-J (S)
WIEK	Wiek	lata (N)
STANRODZ	Liczba osób na utrzymaniu	osoba (D)
TEL	Posiadanie telefonu	Z-J (N)
TELKOM	Posiadanie tel. kom.	Z-J (N)
NIERUCH	Posiadanie nieruchomości	Z-J (S)
MIESZK	Posiadanie mieszkania	Z-J (S)
AUTO	Posiadanie samochodu	Z-J (S)
INNE	Posiadanie innych dóbr	Z-J (S)
DOCHOD	Łączny mies. dochód netto	zł (S)
OBCIAZENIA	Mies. obciążenia z tyt. św.	zł (D)
FP	Zatrudn. w firmie prywatnej	Z-J (D)
GR	Gospodarstwo rolne	Z-J (N)
DZG	Działalność gospodarcza	Z-J (D)
E	Emerytura (lub renta)	Z-J (S)
S.A.	Zatrud. w SA, sp. z o.o., itp.	Z-J (S)
OZ	Okres zatrudnienia	miesiące (S)
WOZ	Wystarczający okres zatrud.	Z-J (S)
OBBANK	Zadłużenie w banku	Z-J (D)
ZUS	Zadłużenie w ZUS	Z-J (D)
KONTO	Posiadanie rach. bank.	Z-J (N)
KWOTAKREDYTU	Kwota kredytu	zł (D)
OKRES KREDYTU	Okres kredytowania	miesiące (D)
ODSETKI	Miesięczne odsetki	zł (D)
LD	Wojew. łódzkie	Z-J (N)
SK	Wojew. skierniewickie	Z-J (N)
SI	Wojew. sieradzkie	Z-J (N)
PT	Wojew. piotrkowskie	Z-J (N)
PL	Wojew. płockie	Z-J (N)
WA	Wojew. warszawskie	Z-J (N)
PS	Przewłaszcz. samoch.	Z-J (N)
PW	Poręczenie wekslowe	Z-J (N)
AC	Cesja praw z polisy AC	Z-J (N)
WIB	Weksel „in blanco”	Z-J (N)
SZR	Sądowy zastaw rejestr.	Z-J (N)

3 MODEL EKONOMETRYCZNY JAKO NARZĘDZIE OCENY KLIENTÓW

Pierwszy etap omawianych badań stanowiła konstrukcja modelu ekonometrycznego, opisującego związek między decyzją o przyznaniu bądź odmowie udzielenia kredytu a kryteriami wpły-

wającymi na ocenę zdolności kredytowej klientów, którzy się o niego ubiegają.

Zgodnie z przyjętym celem badania wyróżniono jedną *zmienną zależną* (DECYZJA), opisującą akceptację bądź odrzucenie wniosków w wybranej próbie klientów banku. Z uwagi na jakościowy charakter rozważanej kategorii, dla potrzeb obliczeniowych zakodowano ją w postaci *binarnej* (zerojedynkowej):

1 - decyzja pozytywna, 0 – decyzja negatywna.

W grupie *zmiennych niezależnych*, determinujących ostateczną decyzję kredytową, uwzględnione zostały natomiast wszystkie wyróżnione cechy potencjalnego kredytobiorcy (por. tab. 1). Z uwagi na późniejszą weryfikację merytoryczną ocen parametrów modelu ekonometrycznego, czynniki te podzielono na:

- stymulanty, pozytywnie wpływające na badane zjawisko (spodziewane dodatnie oszacowania współczynników funkcji regresji),
- destymulanty, negatywnie oddziałujące na zm. objaśnianą (ujemne oceny parametrów),
- nominanty, w przypadku których trudno jest jednoznacznie określić przyczynowy charakter i kierunek związku ze zmienną zależną.

Jednocześnie należy pamiętać, iż obok wymienionych obiektywnych, a jednocześnie łatwych do pomiaru i opisu (jakościowego bądź ilościowego) składników oceny wnioskodawców, w praktyce występuje również szereg elementów wysoce subiektywnych, których bezpośrednie uwzględnienie w konstruowanym modelu nastęrczałoby wielu trudności lub niekiedy było wręcz niemożliwe. Zaliczyć do nich można chociażby: wieloletnie doświadczenie pracowników banku, osobiste odczucia i opinie o kliencie, wynikające z przeprowadzonych rozmów, czy też istotne wiadomości pozyskane przez bank od osób trzecich. W świetle powyższych rozważań wspomniane czynniki zostaną włączone do modelu w postaci *składnika losowego* ξ_i dla $i=1, \dots, 200$. Kategoria ta będzie obejmować ponadto błędy występujące w danych statystycznych, spowodowane niedokładnością pomiarów (np. celowe zawyżanie osiąganych dochodów bądź zaniżanie świadczeń), a także niedoskonałości w specyfikacji modelu, których przyczyna tkwi w ograniczonej wiedzy o prognozowanym zjawisku.

⁸ Symbol Z-J oznacza *zmienną zerojedynkową*. Rodzaj określa *stymulantę* (S), *destymulantę* (D) oraz *nominantę* (N).

3.1 Budowa modelu ekonometrycznego

Zasadniczy cel konstrukcji modelu ekonometrycznego stanowi ujęcie w formie równania (lub części *układu równań*) łącznego wpływu zmiennych objaśniających na zmienną objaśnianą, oraz ogółu powiązań występujących między rozważanymi wielkościami. Z uwagi na *dychotomiczny* charakter zmiennej objaśnianej, najpowszechniej stosowaną w tym przypadku funkcją jest *liniowa funkcja prawdopodobieństwa* (*liniowy model prawdopodobieństwa*), ujmująca zagadnienie binarnej zmiennej zależnej w formie zwykłego zadania regresji liniowej postaci:

$$y_i = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \dots + \alpha_K x_{Ki} + \xi_i,$$

W związku z ograniczeniem wartości przyjmowanych przez zmienną objaśnianą do dwuelementowego zbioru $\{0;1\}$, wyznaczone na podstawie modelu teoretyczne wielkości rozważanego zagadnienia mogą być interpretowane w kategoriach *oszacowań warunkowego prawdopodobieństwa* realizacji określonego zdarzenia (w tym przypadku *przyznania kredytu*) przy ustalonych wartościach zmiennych objaśniających. Niewątpliwą słabość omawianej metody stanowi możliwość otrzymania teoretycznych wartości zmiennej objaśnianej leżących poza przedziałem $\{0;1\}$, co stawia pod znakiem zapytania interpretację uzyskanych rezultatów jako *prawdopodobieństwa*. W zagadnieniu wspomagania decyzji kredytowych fakt ten jednakże nie wydaje się być aż tak poważnym problemem, gdyż otrzymane na podstawie modelu ujemne wartości zmiennej objaśnianej, utwierdzają niejako pracownika banku w przekonaniu, iż dany wniosek kredytowy należy rozpatrzyć negatywnie, natomiast szacunki większe od jedności, potwierdzają zasadność przyznania kredytu.

Konstrukcję modelu ekonometrycznego rozpoczęto od modelu jak najbardziej ogólnego (rozbudowanego), redukując sukcesywnie liczbę zmiennych niezależnych, zgodnie z wynikami prowadzonych analiz statystycznych i ekonometrycznych.

W celu skrócenia zapisu oraz uproszczenia obliczeń wprowadzone zostały następujące zależności o charakterze deterministycznym:

- 1 $\text{DOCHDYS}_i = (\text{DOCHOD}_i - \text{OBCIAZENIA}_i)$
- 2 $\text{KREDMIES}_i = (\text{KWOTAKREDYTU}_i / \text{OKRESKREDYTU}_i + \text{ODSETKI}_i)$
- 3 $\text{DOCH_OS}_i = (\text{DOCHDYS}_i / \text{STANRODZ}_i)$

Ostatecznie, z punktu widzenia docelowej analizy porównawczej, spośród szeregu badanych wariantów modelu ekonometrycznego wybrano trzy równania opisujące szacowaną linię regresji próby 200-elementowej (oznaczone jako *wariant I, V i VII*):

$$(I) \text{DECYZJA}_i = \alpha_0 + \alpha_1 \text{DOCH_OS}_i + \alpha_2 \text{KREDMIES}_i + \alpha_3 \text{AUTO}_i + \alpha_4 \text{NIESAM}_i + \alpha_5 \text{INNE}_i + \alpha_6 \text{TEL}_i + \alpha_7 \text{TELOM}_i + \alpha_8 \text{NIERUCH}_i + \alpha_9 \text{MIESZK}_i + \alpha_{10} \text{DZG}_i + \alpha_{11} \text{E}_i + \alpha_{12} \text{FP}_i + \alpha_{13} \text{GR}_i + \alpha_{14} \text{OZ}_i + \alpha_{15} \text{PS}_i + \alpha_{16} \text{PW}_i + \alpha_{17} \text{AC}_i + \alpha_{18} \text{WIB}_i + \alpha_{19} \text{PL}_i + \alpha_{20} \text{WA}_i + \alpha_{21} \text{SK}_i + \alpha_{22} \text{SI}_i + \alpha_{23} \text{PT}_i + \alpha_{24} \text{WIEK}_i + \alpha_{25} \text{OBBANK}_i + \alpha_{26} \text{ZUS}_i + \alpha_{27} \text{KONTO}_i + \xi_i$$

$$(V) \text{DECYZJA}_i = \alpha_0 + \alpha_1 \text{OBCIAZENIA}_i + \alpha_2 \text{KREDMIES}_i + \alpha_3 \text{WOZ}_i + \alpha_4 \text{NIESAM}_i + \alpha_5 \text{KONTO}_i + \alpha_6 \text{PL}_i + \alpha_7 \text{WA}_i + \alpha_8 \text{SK}_i + \alpha_9 \text{FP}_i + \alpha_{10} \text{PS}_i + \xi_i$$

$$(VII) \text{DECYZJA}_i = \alpha_0 + \alpha_1 \text{KREDMIES}_i + \alpha_2 \text{WOZ}_i + \alpha_3 \text{FP}_i + \xi_i$$

Z uwagi na dysproporcję między ilością pozytywnych (176) oraz negatywnych (24) decyzji kredytowych, w toku dalszych analiz uwzględniono dodatkowy model (postaci tożsamej z wariantem V), którego estymację przeprowadzono w oparciu o próbę złożoną z wniosków rozpatrzonych odmownie (24) i takiej samej liczby losowo wybranych przyznanych kredytów (*wariant VIII*).

We wszystkich zaprezentowanych koncepcjach regresji drugiego rodzaju wykorzystano funkcję liniową w celu odzwierciedlenia związków zachodzących w populacji generalnej. Wybór danej postaci funkcyjnej oparto w głównej mierze na braku przesłanek teoretycznych, zarówno z zakresu ekonomii, jak i bankowości, sugerujących bardziej skomplikowaną formę zależności, opisującej analizowane zjawisko. Istotny wpływ na tę decyzję wywarł również *zerojedynkowy* charakter zmiennej objaśnianej, limitujący możliwość wykorzystania funkcji wykładniczej, czy też potęgowej z uwagi na ograniczony z dołu zbiór ich wartości.

Zasadniczą zaletę przyjętej postaci funkcyjnej (liniowej względem zmiennych, parametrów oraz zakłóceń) stanowi ponadto łatwość i wygoda estymacji parametrów strukturalnych modelu przy użyciu *metody najmniejszych kwadratów*. Niestety niespełnienie założeń dotyczących normalności rozkładu składnika losowego, powoduje utratę przez MNK-estymatory cennych własności, w szczególności podważając zasadność stosowania takich testów, jak *Studenta* czy *Goldfelda-Quandt*, co znacznie utrudnia ocenę statystyczną uzyskanych rezultatów.

Warto podkreślić, iż niespełnienie warunków MNK-estymatora jest problemem stosunkowo często spotykanym przy klasyfikacji klientów w *credit-scoringu*. Z tego też względu dość powszechnie w miejsce regresji liniowej, wykorzystuje się modele: *logitowy* lub *probitowy*. Techniki te pozwalają uniknąć ograniczeń związanych z założeniami wymaganymi w przypadku funkcji liniowej, a prócz tego otrzymane na ich podstawie wartości zmiennej objaśnianej należą do przedziału $\langle 0;1 \rangle$ i mogą być interpretowane w kategoriach prawdopodobieństwa przyznania kredytu.

Za kryterium oceny jakości wybranych modeli ekonometrycznych przyjęto poziom *współczynnika determinacji skorygowanego ilością stopni swobody* (\bar{R}^2). Miara ta, wyznacza stopień korelacji pomiędzy wartościami empirycznymi a teoretycznymi (oszacowanymi na podstawie modelu). Innymi słowy stanowi ona charakterystykę dopasowania równania do danych empirycznych, a ponadto nie zależy od ilości zmiennych objaśniających i może być wykorzystana do porównań modeli różniących się liczbą szacowanych parametrów.

Najlepszy, z punktu widzenia przyjętego kryterium oceny okazał się wariant V (10 zm. objaśniających, 200 obs. w próbie) konstruowanego modelu ($\bar{R}^2=0,2005$). Wartość otrzymanej miary dopasowania sugeruje jednak, iż rozważana funkcja regresji zaledwie w 20,05% objaśnia zmienność decyzji kredytowej. Ten stosunkowo niski poziom precyzji szacunku należy przypisać *binarnej* postaci zmiennej zależnej, wymuszającej generowanie przez model dokładnie wielkości 0 i 1. Powoduje to masowe występowanie pewnych różnic między danymi empirycznymi a teoretycznymi, wywołujących wzrost błędu estymacji.

W związku z występowaniem powyższych reszt został wprowadzony dodatkowy wskaźnik, określający trafność modelowego szacunku w porównaniu z decyzją inspektora kredytowego. Miara ta opiera się na założeniu, że decyzja d_m wydana na podstawie modelu jest pozytywna, jeżeli wartość oszacowana (teoretyczna) jest równa lub przekracza przyjęty próg⁹, oraz negatywna - w pozostałych przypadkach. Warunek ten odpowiada funkcji progowej postaci:

$$d_m = \begin{cases} 0 & \text{gdy } \hat{y} < 0,65 \\ 1 & \text{gdy } \hat{y} \geq 0,65 \end{cases}$$

gdzie

d_m oznacza decyzję modelową, a

\hat{y} oszacowaną wartość zmiennej objaśnianej.

Korzystając z wprowadzonej zależności wskaźnik trafień wyraża się wzorem:

$$w_t = 1 - \frac{\sum_{i=1}^I |d_e^{(i)} - d_m^{(i)}|}{I}$$

gdzie

d_e jest decyzją empiryczną,

i - numerem klienta, zaś

I - liczebnością próby. W rozważanej sytuacji $I = 200$.

Dla rozpatrywanego modelu (10 zm. objaśniających) wskaźnik trafień wynosi $w_t = 0,915$, a zatem decyzja modelowa w 91,5% zgodziła się z opinią pracowników banku. Uzyskany rezultat sugeruje znacznie większą zgodność modelu z danymi, niż wynikało to ze skorygowanego współczynnika determinacji.

4 ROZPATRYWANIE WNIOSKÓW KREDYTOWYCH Z UŻYCIEM SIECI NEURONOWEJ.

Metodą alternatywną dla opisanego wcześniej modelu ekonometrycznego jest konstrukcja sztucznej sieci neuronowej funkcjonującej w oparciu o ten sam zbiór danych empirycznych. Zadanie postawione systemowi neuronowemu zdefiniowano w sposób analogiczny do problemu sformułowanego w analizie regresji, a zatem dotyczyło ono klasyfikacji wniosków pod kątem pozytywnej bądź negatywnej decyzji kredytowej.

Podobnie jak w przypadku modelu ekonometrycznego zmienna objaśniana (prognozowane zjawisko) stanowiła zatem rodzaj binarnego klasyfikatora, sygnalizującego jaką decyzję (pozytywną – 1, negatywną – 0) podjęli inspektorzy kredytowi banku w stosunku do rozpatrywanego wnioskodawcy. Dla zapewnienia porównywalności wyników otrzymanych w analizie regresji z rezultatami dostarczonymi przez sieć neuronową, rozpatrzonych zostało kilka alternatywnych systemów neuronowych,

⁹ Wartość progu klasyfikacji decyzji kredytowej została przyjęta w sposób arbitralny na poziomie 0,65.

odpowiadających kolejnym wersjom proponowanych modeli ekonometrycznych.

Do budowy wszystkich wariantów sieci użyto programu *STATISTICA Neural Network 3.0*.

Z uwagi na ograniczenia, dotyczące zarówno wartości wejściowych, jak i wyjść, narzucone przez program *STATISTICA Neural Networks (SNN)*, wielkości wszystkich zmiennych *niebinarnych* znormalizowano względem odchylenia od wartości minimalnej, transformując tym samym pierwotną dziedzinę w przedział $[0;1]$. Pozwoliło to otrzymać współczynniki wagowe z przedziału $[-1;1]$, zapewniając jednocześnie stabilność procesu uczenia.


Analogicznie jak w przypadku analizy regresji należy spodziewać się, że współczynniki wagowe związane z pewnymi cechami (zmiennymi wejściowymi) będą miały charakter *wzmacniający* (dodatnie wartości), z innymi *hamujący* (ujemne wartości), niektóre zaś powiązania mogą okazać się zbyteczne (wagi zerowe). Uwzględniając jednakże specyfikę procesu przetwarzania informacji oraz stopień komplikacji struktury systemu neuronowego trudno jest w sposób jednoznaczny z góry określić typ poszczególnych połączeń między komórkami.

4.1 Selekcja odpowiedniej architektury sieci

Do konstrukcji wszystkich wspomnianych wariantów sieci neuronowej przyjęto stosunkowo prostą, a zarazem jedną z najczęściej stosowanych architektur, czyli *trzywarstwową sieć jednokierunkową*. Wybór powyższej struktury podyktowany był sugestiami wynikającymi z doświadczeń wielu autorów, zajmujących się problematyką technik neuronowych oraz wnioskami pochodzącymi z serii eksperymentów przeprowadzonych dla *sieci regresji uogólnionej*, a także *liniowej*. Rezultaty uzyskane dla obu wymienionych struktur okazały się bowiem gorsze niż w przypadku sieci trzywarstwowej.

Liczba neuronów w warstwie wejściowej wahała się od 3 do 34 zależnie od rozważanego wariantu tworzonego układu. Analogiczne zróżnicowanie dotyczyło również ilości neuronów w warstwie ukrytej, która dla odpowiednich wersji wynosiła od 2 do 17. Przy wyznaczaniu stosownej do analizowanego przypadku liczby neuronów ukrytych skorzystano z opcji automatycznego jej ustalania przez program *SNN*.

Niezmieniony we wszystkich podejściach pozostał natomiast pojedynczy neuron wyjściowy. Przykładową strukturę sieci dla 10 wejść prezentuje rysunek 1.



Rys. 1. Struktura sieci neuronowej dla wariantu V.

Kolejny istotny aspekt zadanej architektury stanowiły przyjęte funkcje: *postsynaptyczne (PSP)* oraz *aktywacji*. W przypadku pierwszej z nich zarówno dla warstwy ukrytej, jak i wyjściowej¹⁰ wybrano *funkcję liniową*, co w praktyce oznacza, że wartości wychodzące z neuronów jednej warstwy są przemnażane przez odpowiednie współczynniki wagowe, dodawane, po czym od uzyskanej sumy odejmuje się poziom progu (*threshold*). Tak otrzymana wielkość staje się argumentem *funkcji aktywacji*. Zagadnienie wyboru najlepszej, z punktu widzenia analizowanego zjawiska, postaci funkcji aktywacji okazało się jednak bardziej skomplikowane. Problem dotyczył przede wszystkim odwzorowania użytego w warstwie wyjściowej. Wziąwszy bowiem pod uwagę binarny charakter badanego zagadnienia, a także wprowadzony przy okazji modeli ekonometrycznych próg decyzyjny (0,65), właściwą w tym przypadku byłaby *funkcja progowa* z zadaniem przez użytkownika poziomem progu.

Ostatecznie, w obu warstwach (ukrytej i wyjściowej) wykorzystano funkcję logistyczną ze współczynnikiem kształtu $\beta = 1$, której przeciwdziedzina jest przedział $(0;1)$.

4.2 Wybór stosownego algorytmu treningowego i przebieg procesu uczenia

Ostatnim krokiem przed przystąpieniem do rozpoczęcia procesu uczenia (odgrywającego kluczową rolę w konstrukcji każdego systemu

¹⁰ W warstwie pierwszej nie zachodzi przetwarzanie danych, stąd automatycznie program zadaje postać liniową obu powyższych funkcji oraz zerową wartość progu.

neuronowego), było ustalenie *algorytmu treningowego*, właściwego dla rozpatrywanego zagadnienia oraz wybranej architektury. W przypadku wielowarstwowych sieci jednokierunkowych program *SNN* dostarcza pięć różnych możliwości: *metodę wstecznej propagacji błędów*, *algorytm gradientu sprzężonego*, *Levenberga-Marquardta*, *Quickprop* oraz *Delta-Bar-Delta*. Ponownie, opierając się w głównej mierze na opiniach doświadczonych badaczy technik neuronowych, wybrano najpopularniejszą i najlepiej dotychczas poznaną *metodę wstecznej propagacji błędów*, przyjmując jednocześnie *współczynnik uczenia* $\eta = 0,6$ oraz *momentum* $\lambda = 0,3$.

Z 200-elementowego zbioru danych empirycznych, 150 (75%) losowo wytypowanych obserwacji użyto jako wzorców uczących, a pozostałe 50 (25%) jako weryfikujących poprawność działania sieci. Pewne wątpliwości budzi fakt, iż mimo stosunkowo zadowalającej liczby zgromadzonych obserwacji, występuje wyraźna ilościowa przewaga wniosków rozpatrzonych pozytywnie (88%) nad odmowami (12%). W związku z powyższym, dla porównania rezultatów trening sieci przeprowadzono również na identycznej, jak przy konstrukcji modelu ekonometrycznego, próbie zredukowanej do 48 obserwacji, z której 38 elementów stanowiło zbiór uczący, a pozostałe 10 weryfikujący.

W przypadku próby 200-elementowej systemowi neuronowemu zaprezentowano 500 epok, zaś przy zbiorze okrojonym – 300. Wiazało się to ze spadkiem błędu uczenia i jednoczesnym wzrostem błędu weryfikacji, występującym przy zwiększeniu liczby kolejnych epok. Zjawisko takie sugerowało, iż sieć zaczyna „uczyć się na pamięć”, tracąc tym samym zdolność generalizacji, i stanowiło podstawę do skrócenia treningu. Próbkę w zbiorze uczącym były ustawione w kolejności losowej, zaś korekcja wag miała charakter *wsadowy*, to znaczy następowała po każdej epoce.

Za kryterium oceny jakości poszczególnych wersji sieci przyjęto przede wszystkim wprowadzony wcześniej *wskaźnik trafień*, określający trafność prognozy systemu neuronowego w porównaniu z decyzją inspektorów kredytowych. Wartość zadanego progu decyzyjnego wynosiła 0,65, analogicznie do poziomu wykorzystanego w analizie regresji.

5 ANALIZA PORÓWNAWCZA METOD WYKORZYSTANYCH W BADANIACH

Dla zapewnienia porównywalności wyników między zastosowanymi metodami klasyfikacji wniosków kredytowych, oba rodzaje eksperymentów przeprowadzono w identycznych warunkach, to znaczy wykorzystując odpowiednie próby statystyczne oraz uwzględniając analogiczne zbiory zmiennych objaśniających. W celu oceny jakości prognozy dostarczonej przez obie techniki, dla każdej z nich wyznaczono ten sam zbiór miar dopasowania oraz błędów.

Tabela 2. Wartości skorygowanych współczynników determinacji dla wybranych modeli oraz sieci.

Wariant	Skorygowany współczynnik determinacji (\bar{R}^2)	
	Model	Sieć
Wariant I (27 zm., 200 obs)	,1096	,6538
Wariant V (10 zm., 200 obs)	,2005	,4129
Wariant VII (3 zm., 200 obs)	,1592	,1812
Wariant VIII (10 zm., 48 obs)	,2630	,3677

Oceniając dopasowanie wartości teoretycznych do danych empirycznych na podstawie *skorygowanych współczynników determinacji*, należy stwierdzić, iż w każdym z wybranych wariantów systemy neuronowe okazały się techniką efektywniejszą, w sensie procentowego poziomu objaśnienia zmienności rozważanego problemu. Dotyczy to zwłaszcza *wariantu I* (27 zm., 200 obs.), dla którego otrzymana wartość wspomnianego współczynnika sugeruje, że skonstruowana sieć w 65,38% jest w stanie wyjaśnić zachowanie prognozowanej zmiennej. Rezultat ten można uznać za wysoce zadowalający, zważywszy na fakt, iż klasyfikacja wniosków kredytowych należy do zagadnień, na które ogromny wpływ mają czynniki losowe trudne do przewidzenia (nie mówiąc już o uwzględnieniu ich w zbiorze zmiennych objaśniających). Wyciągnięte dotychczas wnioski wydaje się potwierdzać wzrokowa analiza wykresów teoretycznych oraz empirycznych decyzji kredytowych, zamieszczonych w dalszej części pracy. Warto zauważyć ponadto ciekawą zależność między poziomem współczynnika determinacji a ilością wejść w omawianych wariantach systemu neuronowego. Wartość miary dopasowania maleje bowiem wraz z ograniczaniem liczby zmiennych objaśniających, co

potwierdza przypuszczenia, że niektóre zmienne, nieistotne z punktu widzenia analizy regresji, w przypadku sieci neuronowej mogą mieć wpływ na decyzję kredytową.

Wątpliwości może budzić zasadność porównywania skorygowanych współczynników determinacji obliczonych dla każdej z technik, z uwagi na brak bezpośredniego uwzględnienia wyrazu wolnego w wynikach przedstawionych dla sieci. Składnik ten w systemach neuronowych występuje jednak pośrednio w postaci wspomnianego wcześniej *progu* (*obciążenia*, *bias*, *threshold*) i w danej formie został on uwzględniony w przeprowadzonych obliczeniach.

Na korzyść technik neuronowych przemawiają również wyznaczone wielkości *wskaźnika trafień*, choć w przypadku tej miary rozbieżności między modelami ekonometrycznymi a sieciami nie są już tak znaczne.

Tabela 3. Wartości wskaźnika trafień dla wybranych wariantów modelu i sieci.

Wariant	Wskaźnik trafień (w_t) [%]	
	Model	Sieć
Wariant I (27 zm., 200 obs.)	90,50	95,00
Wariant V (10 zm., 200 obs.)	91,50	92,50
Wariant VII (3 zm., 200 obs.)	89,00	90,50
Wariant VIII (10 zm., 48 obs.)	77,00	81,25

Przyczyny takiego stanu rzeczy można dopatrywać się w lepszym dopasowaniu szacunków systemów neuronowych do danych empirycznych, a tym samym większą trafnością prognozy. Potwierdzają to także wielkości odchylenia standardowego reszt (*SEE*).









Tabela 4. Wartości wybranych miar błędów prognozy.

Wariant	SEE		MAE		RMSE	
	Model	Sieć	Model	Sieć	Model	Sieć
Wariant I	,290	,178	,190	,048	,285	,178
Wariant V	,280	,240	,173	,098	,280	,243
Wariant VII	,300	,290	,175	,150	,296	,292
Wariant VIII	,380	,360	,373	,225	,417	,357

Jak widać na zamieszczonych poniżej wykresach, systemy neuronowe wydają się być bardziej „stanowcze” w podejmowanych decyzjach, podczas gdy modele ekonometryczne pozostawiają większy margines niepewności. Interpre-

tując uzyskane w obu metodach rezultaty w kategoriach *prawdopodobieństwa* przyznania kredytu¹¹, można by powiedzieć, iż w przypadku sieci, dla klientów których wnioski inspektorzy kredytowi rozpatrzyli pozytywnie, oszacowane prawdopodobieństwo było z reguły większe, w porównaniu z wynikami analizy regresji. Stąd ustalony próg klasyfikacji (obecnie 0,65) mógłby, przy zastosowaniu techniki neuronowej, być zdecydowanie wyższy, bez istotnego wpływu na poziom wprowadzonego wskaźnika trafień. Podobna sytuacja dotyczy decyzji negatywnych, dla których wartości prawdopodobieństw, otrzymane na podstawie systemów neuronowych, były odpowiednio niższe niż szacunki pochodzące z modelu. Powyższe prawidłowości łatwo zauważyć zwłaszcza w *wariancie I* (27 zm., 200 obs.), posiadającym największą, w stosunku do pozostałych zaprezentowanych wersji, liczbę zmiennych objaśniających. Spostrzeżenia te wydają się potwierdzać, relatywnie wysokie w tym przypadku, wielkości miar dopasowania: skorygowanego współczynnika determinacji ($\bar{R}^2 = 65,38\%$) i wskaźnika trafień ($w_t = 95\%$). Porównanie wykresów sporządzonych dla *wariantu I* (27 zm., 200 obs.) oraz *wariantu V* (10 zm., 200 obs.) prowadzi do wniosku, iż zasadna, z punktu widzenia analizy regresji, redukcja zmiennych niezależnych, niekorzystnie wpływa na rezultaty sieci. Ponownie sugeruje to możliwość występowania głęboko ukrytych związków między wyeliminowanymi cechami diagnostycznymi a decyzją kredytową, wykrytych i wykorzystywanych przez systemy neuronowe. Omawiane zjawisko można zauważyć zwłaszcza na przykładzie grupy klientów, których wnioski rozpatrzono odmownie. Niskie prawdopodobieństwo udzielenia kredytu oszacowane w *wariancie I* (27 zm., 200 obs.) jest w większości rozważanych przypadków wyższe w *wariancie V* (10 zm., 200 obs.). Jednocześnie dla znacznej części wnioskodawców, którym przyznano kredyt, wysokie wartości prawdopodobieństwa, wyznaczone przez sieć w *wariancie I*, w *wariancie V* nieco spadają. Sytuacja ta prowadzi do pogorszenia miar dopasowania szacunków systemu neuronowego do danych empirycznych (*wariant V*: $\bar{R}^2 = 41,29\%$, $w_t = 92,5\%$).

¹¹ Proponowana interpretacja jest tym wygodniejsza, iż z uwagi na użycie logistycznej funkcji aktywacji w warstwie wyjściowej sieci, szacunki systemu neuronowego, należą do przedziału (0;1).



Zmniejszenie rozbieżności między wynikami analizy regresji i technik neuronowych widać natomiast wyraźnie na wykresach *wariantu VII* (3 zm., 200 obs.), które wydają się być najbardziej do siebie zbliżone, podobnie jak wielkości skorygowanych współczynników determinacji

(model: $\bar{R}^2 = 15,92\%$, sieć: $\bar{R}^2 = 18,12\%$) oraz wskaźników trafień (model: $w_t = 89\%$, sieć: $w_t = 90,5\%$).

Warto ponadto zauważyć, iż w stosunku do pewnej grupy wnioskodawców sieci miały znacznie większe wątpliwości niż modele

ekonometryczne. Dotyczyły one zarówno kilku decyzji pozytywnych, wydanych przez pracowników banku, jak i negatywnych. Zastrzeżenia te są najlepiej widoczne w *wariancie I* (27 zm., 200 obs) i *V* (10 zm., 200 obs.). Potwierdzają to różnice między poziomem średnich absolutnych błędów (*MAE*) a wyznaczonymi błędami średniokwadratowymi (*RMSE*), które sugerują występowanie zbioru reszt o skrajnie dużych wartościach. Najmniejsze rozbieżności między powyższymi miarami odnotowano natomiast w obu technikach dla wariantu z 10 zmiennymi objaśniającymi, oszacowanego na podstawie zbioru obserwacji zredukowanego do 48 elementów. Wiąże się to z faktem, iż zarówno dla równania regresji, jak i systemu neuronowego, zwłaszcza w przypadku pozytywnej decyzji empirycznej, wielkości teoretyczne były systematycznie niedoszacowane, co powodowało wzrost obu rozważanych miar błędów.

Najlepszym rozstrzygnięciem kwestii, czy zastrzeżenia zgłaszane przez sieć miały głębsze uzasadnienie, czy też okazały się bezpodstawne, byłaby analiza terminowości spłat kredytów przyznanych „podejrzanym” wnioskodawcom, lecz niestety nie jest ona możliwa z uwagi na brak niezbędnych informacji. Jeszcze większe problemy pojawiają się przy próbie odpowiedzi na pytanie: „Czy w grupie odrzuconych wniosków nie znaleźli się potencjalnie sumienni klienci?”.

6 PODSUMOWANIE

Zaprezentowane badania miały na celu porównanie efektywności sieci neuronowych i modeli ekonometrycznych we wspomaganiu decyzji kredytowych. Wartości *wskaźnika trafień* (przy ustalonym progu decyzyjnym) dla większości analizowanych wariantów, zarówno modeli ekonometrycznych, jak i sieci, przekroczyły 90%. Wysoki poziom powyższej miary wskazuje na znaczną zgodność wyników, dostarczonych przez zobiektywizowane metody ilościowe, z ostateczną decyzją doświadczonych pracowników banku, sugerując jednocześnie większą efektywność wykorzystanych narzędzi niż wynikałoby to z wartości skorygowanego współczynnika determinacji.

Otrzymane wyniki można uznać za szczególnie zadowalające, zwłaszcza jeśli wziąć pod uwagę fakt, iż procedury oceny ryzyka kredy-

towego oraz klasyfikacji wnioskodawców, nie są prostymi, deterministycznymi funkcjami określonych cech potencjalnych dłużników. Istotną rolę odgrywa w nich również subiektywny czynnik ludzki, wprowadzający element losowości do złożonego systemu udzielania kredytów.

Analiza porównawcza wspomnianych miar dopasowania i błędów przemawiała nieco na korzyść systemów neuronowych, choć fakt ten nie przesądza jednoznacznie o większej efektywności danej metody. Obie techniki posiadają bowiem cenne własności, wnoszące istotny wkład do prowadzonych badań.

Zasadniczą zaletą sieci jest z całą pewnością zdolność wykrywania związków głęboko ukrytych we wzorcach empirycznych, których nie sposób uwzględnić w modelu ekonometrycznym na podstawie posiadanej wiedzy teoretycznej. Potwierdza to wartość *wskaźnika trafień* obliczona dla dodatkowego wariantu sieci wykorzystującego maksymalną liczbę 34 zmiennych objaśniających ($w_i = 96\%$). Wspomniana ilość wejść pozwala uwzględnić wszystkie posiadane informacje o kliencie, spośród których pewne fakty (na pozór nieistotne) mogą jednak zawierać dane determinujące poziom prognozowanego zjawiska. Obliczone dla danej wersji systemu neuronowego poziomy odchylenia standardowego reszt ($SEE_A = 0,185$), średniego absolutnego błędu ($MAE_A = 0,058$), a także błędów średniokwadratowych ($MSE_A = 0,034$, $RMSE_A = 0,185$), wskazują na zadowalające dopasowanie szacunków do danych empirycznych, a ponadto są z reguły niższe niż wielkości otrzymane dla pozostałych wariantów sieci oraz odpowiadających im modeli ekonometrycznych.

Na niekorzyść systemów neuronowych przemawia natomiast brak interpretacji współczynników wagowych oraz wciąż słabo poznane szczegóły zasad funkcjonowania. Mimo większej precyzji prognoz sieci, nie można na ich podstawie przeprowadzić wnioskowania dotyczącego istotności poszczególnych cech diagnostycznych dla ostatecznej decyzji kredytowej, a tym samym w jednoznaczny sposób wskazać zbioru zmiennych o największym znaczeniu.

Pod tym względem modele ekonometryczne stanowią znacznie lepsze narzędzie analityczne, dostarczające cennych informacji o związkach zachodzących w badanym zagadnieniu. Niepodważalny atut analizy regresji stanowi możliwość analizy i oceny jakości otrzymanych wyników na podstawie sprawdzonych testów statystycz-

nych, a także wyznaczenia czynników wywierających decydujący wpływ na omawiane zjawisko.

Jak wynika z prac autorów zajmujących się problematyką ilościowych metod doboru odpowiednich kredytobiorców, trudno jest wskazać najbardziej efektywną z nich. Wysuwane wnioski w dużym stopniu zależą bowiem od danych wykorzystanych w badaniach. Stąd też powszechna opinia, iż mając do wyboru kilka modeli klasyfikacji potencjalnych kredytobiorców, najlepsze rezultaty daje łączne uwzględnienie wyników, generowanych przez każdy z nich.¹²

Mimo, iż przeprowadzone badania miały przede wszystkim charakter teoretyczny, fakt ten nie podważa praktycznej przydatności stworzonych układów. Jako techniki wspomagania procesu decyzyjnego, mogą być one wykorzystane we wstępnej ocenie wnioskodawców, stanowiącej punkt wyjścia do dalszych analiz, dokonywanych przez inspektorów kredytowych. Ich znaczenie wiąże się ponadto z wtórną weryfikacją wystąpień klientów, w przypadku których metody ilościowe miały zastrzeżenia zarówno w sensie negatywnym, jak i pozytywnym. Ponowna analiza danych wniosków pozwala zmniejszyć prawdopodobieństwo strat powstałych w wyniku udzielania kredytów nierzetelnym dłużnikom, a także zapobiec utracie możliwych do uzyskania przychodów wskutek nieprzyznania kredytu potencjalnie dobrym klientom.

W celu obiektywnej oceny praktycznej przydatności obu narzędzi analitycznych, sensowna byłaby weryfikacja poprawności ich działania na zbiorze nowych danych empirycznych, dotyczących jednakże tej samej populacji wnioskodawców w danej jednostce banku.

Podsumowując powyższe rozważania należy stwierdzić, iż przewaga systemów neuronowych nad równaniami regresji w *każdym* z porównywanych wariantów, zarówno pod kątem miar dopasowania, jak i błędów, sugeruje zasadność przeprowadzenia dalszych badań, najlepiej dla rozszerzonej, i w miarę możliwości zbilansowanej (pod względem ilości pozytywnych i negatywnych decyzji kredytowych) próby statystycznej oraz nowych wariantów obu omawianych technik.

BIBLIOGRAFIA

- 1) Żurada, J., Barski, M., Jędruch, W. (1996). *Sztuczne sieci neuronowe: podstawy teorii i zastosowania*. Warszawa: PWN.
- 2) Masters, T. (1996). *Sieci neuronowe w praktyce*. Warszawa: Wydawnictwo Naukowo – Techniczne.
- 3) Gately, E. *Sieci neuronowe. Prognozowanie finansowe i projektowanie systemów transakcyjnych*. (1999). Warszawa: WIG Press.
- 4) Osowski, S. *Sieci neuronowe do przetwarzania informacji*. (2000). Warszawa: Oficyna Wydawnicza Politechniki Warszawskiej.
- 5) Hertz, J., Krogh, A., Palmer, R.G. *Wstęp do teorii obliczeń neuronowych*. (1993). Warszawa: Wydawnictwo Naukowo-Techniczne.
- 6) *STATISTICA Neural Networks - documentation*. (1998). Tulsa, USA: StatSoft, Inc.
- 7) Azoff, E.M. *Neural network time series forecasting of financial markets*. (1994). Chichester: John Wiley & Sons Ltd.
- 8) Zieliński, P. *Systemy informatyczne dla bankowości w zarysie*. (1998). Warszawa: Akademicka Oficyna Wydawnicza PLJ.
- 9) Jaworski, W.L., Krzyżkiewicz, Z., Kosiński, B. *Banki – rynek, operacje, polityka*. (1999). Warszawa: POLTEXT.
- 10) Borys, G. *Zarządzanie ryzykiem kredytowym w banku*. (1996). Warszawa: PWN.
- 11) Patterson, R. *Poradnik kredytowy dla bankowców*. (1995). Warszawa: TWIGGER.
- 12) Herpolitańska, J., Borowska, E. *Kredyty i gwarancje bankowe*. (1993). Warszawa: TWIGGER.
- 13) Janc, A., Kraska, M. *Credit-scoring. Nowoczesna metoda oceny zdolności kredytowej*. (2001). Warszawa: Zarządzanie i finanse.
- 14) Gajda, J. *Ekonometria praktyczna*. (1996). Łódź: Absolut.
- 15) Welfe, A. *Ekonometria. Metody i ich zastosowanie*, (1998). Warszawa: PWE.
- 16) Goldberger, A.S. *Teoria ekonometrii*. (1972). Warszawa: PWE.
- 17) Kuryłek, W. Credit scoring – podejście statystyczne. *Bank i kredyt*. 2000, 6.
- 18) Rex, P.J.L. Strategia kredytowa – podejście praktyczne i jego zastosowanie. *Bank*. 1995, 2, 45-49.
- 19) Dura, A. O naturze ryzyka kredytowego. *Bankowe abc. Bank i Kredyt*. 2000, 7-8, 1-15.
- 20) Boyes, W.J., Hoffman, D.L., Low, S.A. An econometric analysis of the bank credit scoring problem. *Journal of Econometrics*. 1989, 40.

¹² Kuryłek, W. Credit scoring – podejście statystyczne. *Bank i kredyt*. 2000, 6, s. 76.